



**UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO**  
**CENTRO TECNOLÓGICO**  
**COLEGIADO DE ENGENHARIA MECÂNICA**

Renner Tetzner Ramos

# **Diagnóstico automático de falhas em máquinas rotativas utilizando máquina de vetores-suporte**

Vitória, ES

2020

Renner Tetzner Ramos

## **Diagnóstico automático de falhas em máquinas rotativas utilizando máquina de vetores-suporte**

Trabalho de Conclusão de Curso apresentado  
ao Departamento de Engenharia Mecânica do  
Centro Tecnológico da Universidade Federal  
do Espírito Santo, como requisito parcial para  
obtenção do grau de Engenheiro Mecânico.

Universidade Federal do Espírito Santo — UFES

Centro Tecnológico

Departamento de Engenharia Mecânica

Orientador: Prof. Luis Gustavo Giacon Villani

Vitória, ES

2020

Renner Tetzner Ramos

## **Diagnóstico automático de falhas em máquinas rotativas utilizando máquina de vetores-suporte**

Trabalho de Conclusão de Curso apresentado  
ao Departamento de Engenharia Mecânica do  
Centro Tecnológico da Universidade Federal  
do Espírito Santo, como requisito parcial para  
obtenção do grau de Engenheiro Mecânico.

Trabalho aprovado. Vitória, ES, 06 de maio de 2021:

---

**Prof. Luis Gustavo Giacon Villani**  
Orientador

---

**Prof. Lucas Silveira Campos**  
Convidado 1

---

**Prof. Márcio Coelho de Mattos**  
Convidado 2

Vitória, ES  
2020

# Resumo

A manutenção de processos industriais críticos exige um monitoramento de máquinas bem estruturado, o mais importante deles o monitoramento de vibrações. São etapas imprescindíveis para tal: a coleta do sinal, o seu processamento e a análise dos dados extraídos, de modo a detectar e diagnosticar danos antes da ocorrência de potenciais falhas. A aplicação de modelos de aprendizado de máquina (AM) pode automatizar esta última etapa, por isso tem recebido bastante atenção na indústria e na academia. Modelos de AM, no entanto, se baseiam em dados, de modo que a escolha do conjunto de indicadores do estado da máquina implica diretamente nos resultados do modelo. O presente trabalho tem como objetivo realizar o processamento da base de dados de vibração de rotores MAFAULDA, implementar um modelo de classificação supervisionada Máquina de Vetores-Suporte (SVM) e explorar como diferentes conjuntos de características afetam o seu desempenho. Com isso, busca-se, a partir de uma base de dados conhecida, extrair conhecimentos que possam orientar a construção de modelos mais robustos e generalizáveis.

**Palavras-chave:** Manutenção preditiva. Processamento de sinais. Extração de características. Aprendizado de máquina.

# Lista de figuras

Figura 1 – Componentes da bancada. . . . .	14
Figura 2 – Mancais instrumentados. . . . .	15
Figura 3 – Instrumentação da bancada. . . . .	17
Figura 4 – Eixos de medição. . . . .	17
Figura 5 – Transformada de Fourier para a identificação dos componentes em frequência. . . . .	18
Figura 6 – Causa do desbalanceamento. . . . .	19
Figura 7 – Diagnóstico do desbalanceamento. . . . .	20
Figura 8 – Diagnóstico do desalinhamento paralelo. . . . .	20
Figura 9 – Redução da frequência de amostragem. . . . .	23
Figura 10 – Sinal do tacômetro a uma rotação de 32,8 Hz. . . . .	24
Figura 11 – Sinais no tempo e histogramas por eixo, para um caso de 35g de desbalanceamento a 32,8 Hz de rotação. . . . .	26
Figura 12 – Aprendizado supervisionado. . . . .	29
Figura 13 – Fronteiras de decisão no plano. . . . .	31
Figura 14 – Validação cruzada com 5 partições ( $K = 5$ ). . . . .	32
Figura 15 – Etapas para a geração do classificador de falhas. . . . .	33
Figura 16 – Representações da fase do sinal, no eixo Tangencial 1 . . . . .	36
Figura 17 – Espectro FFT dos sinais por categoria de defeito, à rotação de aprox. 57 Hz. . . . .	36
Figura 18 – Espectro dos sinais no primeiro mancal e posição do centro de frequência, para um caso de 35g de desbalanceamento a 32,8 Hz de rotação. . . . .	38
Figura 19 – Box-pot da acurácia por grupos de características. . . . .	39
Figura 20 – Box-pot da acurácia por eixos. . . . .	40
Figura 21 – Gráfico em cascata para cada condição, no eixo tangencial do primeiro mancal. . . . .	50

# Lista de tabelas

Tabela 1 – Especificações da bancada (adaptada de MAFAULDA (2017)) . . . . .	15
Tabela 2 – Especificações dos acelerômetros (adaptado de MAFAULDA (2017)) .	16
Tabela 3 – Quantidade de ensaios por defeito inserido (adaptada de MAFAULDA (2017)) . . . . .	21
Tabela 4 – Estatísticas dos sinais no tempo $x[i]$ e na frequência $X[i]$ (adaptada de Rauber, Boldt e Varejao (2015) e Xia et al. (2012)) . . . . .	27
Tabela 5 – Quantidade de características por grupos. . . . .	28
Tabela 6 – Acurácia por grupos de características. . . . .	34
Tabela 7 – Matriz de confusão utilizando características do espectro. . . . .	37
Tabela 8 – Matriz de confusão utilizando características estatísticas. . . . .	38
Tabela 9 – Matriz de confusão utilizando todas as características. . . . .	39
Tabela 10 – Acurácia por eixos de medição selecionados. . . . .	40
Tabela 11 – Matriz de confusão para acelerômetro triaxial no mancal interno. . . .	40
Tabela 12 – Matriz de confusão para pares de acelerômetros radiais. . . . .	41

# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>8</b>
<b>1.1</b>	<b>Diagnóstico automático de falhas</b>	<b>9</b>
<b>1.2</b>	<b>Objetivos</b>	<b>9</b>
1.2.1	Objetivo geral	9
1.2.2	Objetivos específicos	9
<b>1.3</b>	<b>Estrutura do trabalho</b>	<b>10</b>
<b>2</b>	<b>REVISÃO BIBLIOGRÁFICA</b>	<b>11</b>
<b>2.1</b>	<b>Núcleo NINFA da UFES</b>	<b>11</b>
<b>2.2</b>	<b>Utilizando a base de dados MAFAULDA</b>	<b>12</b>
<b>2.3</b>	<b>Conclusão</b>	<b>13</b>
<b>3</b>	<b>DESCRIÇÃO DOS DADOS</b>	<b>14</b>
<b>3.1</b>	<b>Bancada de vibração e instrumentação</b>	<b>14</b>
<b>3.2</b>	<b>Falhas simuladas e suas assinaturas</b>	<b>18</b>
3.2.1	Desbalanceamento	18
3.2.2	Desalinhamento horizontal	19
3.2.3	Desalinhamento vertical	21
<b>3.3</b>	<b>Resumo</b>	<b>21</b>
<b>4</b>	<b>EXTRAÇÃO DE CARACTERÍSTICAS</b>	<b>22</b>
<b>4.1</b>	<b><i>Downsampling</i> dos sinais de vibração</b>	<b>22</b>
<b>4.2</b>	<b>Análise do espectro</b>	<b>22</b>
4.2.1	Frequência de rotação	24
4.2.2	Componentes harmônicos	24
4.2.3	Ângulos de fase	25
<b>4.3</b>	<b>Valores estatísticos</b>	<b>25</b>
4.3.1	Vetor de características	27
<b>5</b>	<b>APRENDIZADO DE MÁQUINA SUPERVISIONADO</b>	<b>29</b>
<b>5.1</b>	<b>Classificador máquina de vetores-suporte</b>	<b>30</b>
<b>5.2</b>	<b>Métricas e validação</b>	<b>32</b>
<b>5.3</b>	<b>Fluxo de dados e <i>software</i> utilizado</b>	<b>33</b>
<b>6</b>	<b>ANÁLISE DOS RESULTADOS</b>	<b>34</b>
<b>6.1</b>	<b>Desempenho por características</b>	<b>34</b>
6.1.1	Características do espectro	35

6.1.2	Características estatísticas . . . . .	37
6.1.3	Resumo . . . . .	38
<b>6.2</b>	<b>Desempenho por eixos de medição . . . . .</b>	<b>39</b>
<b>6.3</b>	<b>Conclusão . . . . .</b>	<b>41</b>
<b>7</b>	<b>CONSIDERAÇÕES FINAIS . . . . .</b>	<b>42</b>
<b>7.1</b>	<b>Conclusões . . . . .</b>	<b>42</b>
<b>7.2</b>	<b>Trabalhos futuros . . . . .</b>	<b>43</b>
	<b>REFERÊNCIAS . . . . .</b>	<b>45</b>
	<b>APÊNDICE A – GRÁFICOS EM CASACTA . . . . .</b>	<b>49</b>



# 1 Introdução

No ambiente industrial, existem ao menos 3 estratégias básicas de manutenção: a corretiva, a preventiva e a preditiva. Desde o princípio da atividade industrial pratica-se a manutenção corretiva. Reativa por natureza, nela o equipamento só passa por intervenção quando há falha. Essa abordagem costuma gerar danos colaterais maiores e paradas imprevisíveis. Atendendo a tais problemas, surge a manutenção preventiva. Nela, as intervenções são planejadas e se baseiam na estimativa do tempo de falha. A última estratégia diz respeito à manutenção preditiva, que apresenta claras vantagens em relação às anteriores (GIRDHAR; SCHEFFER, 2004).

Na manutenção preditiva busca-se, através do monitoramento contínuo ou em intervalos regulares de tempo, a projeção do estado da máquina e a verificação dos níveis de alarme que antecipem a ocorrência da falha. Desta forma, maximiza-se a vida útil dos componentes críticos enquanto simultaneamente mitigam-se riscos e custos, pois toda a intervenção da manutenção é fundamentada em informações da própria máquina.

Dados da ABRAMAN (2017) apontam que em torno de 78% do trabalho de manutenção nas empresas é direcionado a manutenções corretivas e preventivas, restando apenas 22% à preditiva e outras atividades. Apesar de o monitoramento de máquinas ter apresentado avanços desde a década de 70, há claro espaço para melhoria, que passa por maior aprofundamento técnico em 3 áreas fundamentais: a detecção, o diagnóstico e o prognóstico de falhas (RANDALL, 2004).

A técnica mais aceita para a detecção de falhas em máquinas rotativas é o monitoramento de vibração. Este monitoramento pode ser periódico ou contínuo, sem que haja prejuízo à produção. Sua prática regular pode indicar a deterioração do equipamento e de sua condição de operação. Detectam-se rolamentos defeituosos, folgas, desgastes e quebras de engrenagem, condições e ocorrências típicas que surgem ao longo da vida útil de máquinas rotativas. (GIRDHAR; SCHEFFER, 2004).

Más práticas de instalação, manutenção e operação também são acusadas pela vibração da máquina. A análise desse sinal pode apontar imprecisão tanto no alinhamento de eixos, quanto no balanceamento de rotores, os problemas mais comuns em máquinas rotativas. Estes problemas acabam potencializando danos ao equipamento quando associados a outras causas de falha, como a operação acima da capacidade planejada ou falhas de projeto. Além de dano, esta combinação de situações de risco pode ocasionar perdas e incidentes que só poderão ser evitados quando há o diagnóstico precoce destes problemas. Reafirma-se, portanto, a importância do monitoramento de vibração para a garantia da confiabilidade e da disponibilidade dos equipamentos e sistemas rotativos.

## 1.1 Diagnóstico automático de falhas

A análise do sinal de vibração tipicamente depende de especialistas qualificados, que são escassos e cuja qualificação é onerosa (LOUREIRO, 2009). Ao mesmo tempo, é crescente o acesso às informações de operação das máquinas, à medida que são introduzidos equipamentos inteligentes na indústria (BELLO; ZEADALLY, 2016). Para aproveitar essa maior oferta de dados, especialmente os de vibração, é de grande interesse para a equipe de manutenção dispor de um sistema capaz de utilizá-los de forma automática no diagnóstico de falhas em potencial. Um sistema de diagnóstico que seja abrangente e assertivo.

Para a realização desse sistema, pode-se recorrer a técnicas baseadas em modelagem analítica, ou a técnicas baseadas em reconhecimento de padrões (WANDEKOKEM, 2011). A modelagem analítica do conjunto vibracional depende de um experimento montado em laboratório, utilizando atuadores, controladores e sensores. Para cada estímulo fornecido, geram-se leituras de saída correspondentes e com estas relações definem-se as equações diferenciais descritivas para o conjunto. No entanto, a complexidade da maioria dos problemas práticos impede a adoção dessa metodologia na indústria. A abordagem alternativa se baseia no reconhecimento automático de padrões a partir de dados de treinamento rotulados, usando técnicas de aprendizado de máquina (AM).

A aplicação de técnicas de AM no diagnóstico de falhas gera como produto um modelo que recebe os dados da máquina e, com base neles, indica a presença de um defeito ao qual ele foi “treinado” para identificar. Para o sucesso do modelo, deve-se treiná-lo com dados de máquinas que tenham configuração semelhante às que serão monitoradas posteriormente. Também é muito importante buscar uma representação dos dados adequada para a identificação de cada defeito que se deseja avaliar. Portanto, utilizar uma base de dados representativa e variada é de grande importância para o projeto de AM aplicado.

## 1.2 Objetivos

### 1.2.1 Objetivo geral

Neste trabalho pretende-se desenvolver um projeto de AM a partir dos dados de vibração presentes na base MAFAULDA (2017) para o diagnóstico automático de falhas em rotores, utilizando um classificador SVM linear para um problema com quatro classes de defeito: desbalanceamento, desalinhamento horizontal, desalinhamento vertical ou condição normal.

### 1.2.2 Objetivos específicos

Para a realização do objetivo geral será buscada a realização das seguintes etapas e objetivos complementares:

- discutir as etapas de um projeto de AM aplicado ao diagnóstico de falhas e apresentar trabalhos de referência;
- definir, extrair e analisar características relevantes dos sinais de vibração;
- testar o desempenho do classificador utilizando diferentes sub-conjuntos de características; e
- testar o impacto da redução da instrumentação no desempenho do classificador.

### 1.3 Estrutura do trabalho

O trabalho está dividido conforme segue:

- **Revisão bibliográfica:** são mencionadas as abordagens exploradas em trabalhos anteriores para o uso de AM no diagnóstico de falhas;
- **Descrição dos dados:** são discutidas com maior detalhe o banco de dados utilizado, as classes de defeito e suas assinaturas na frequência;
- **Extração de características:** são descritas as técnicas de processamento de sinais e de extração de características;
- **Aprendizado de máquina supervisionado:** são apresentados o algoritmo AM utilizado e suas técnicas de validação;
- **Análise dos resultados:** são fornecidas visualizações das características extraídas e é apresentado o desempenho do modelo em diferentes testes; e
- **Considerações Finais:** são destacados as contribuições do trabalho, as suas limitações e são sugeridos aprofundamentos no estudo do diagnóstico de defeitos a partir de bancadas de vibração.

## 2 Revisão bibliográfica

A manutenção baseada no monitoramento de máquinas depende de 3 processos-chave: aquisição de dados; processamento de dados; e tomada de decisão (JARDINE; LIN; BANJEVIC, 2006). Durante a fase de *aquisição* (cp. 3), obtêm-se dados tanto sobre a condição da máquina, quanto sobre eventos de falhas e de intervenção. A principal técnica de monitoramento é o monitoramento de vibrações. Esta escolha advém da alta concentração de informação no sinal, a redução dos custos dos instrumentos e a agilidade de captação.

Na fase de *processamento de dados*, diversas técnicas podem ser aplicadas para se extrair informações agregadas do sinal de vibração. Chama-se esse processo de extração de características (cp. 4). É muito importante que após este processo sejam geradas características que representem adequadamente o estado da máquina, ou seja, é imprescindível escolher características que sejam sensíveis a ocorrências de falhas. Por fim, há a fase de *tomada de decisão*, que se divide em 2 procedimentos distintos. Há o diagnóstico, quando se mapeiam os dados obtidos do espaço de características para fins de classificação de falhas (cp. 5), e há o prognóstico, quando se estipula também o estado de degradação da máquina e a sua vida útil remanescente (JARDINE; LIN; BANJEVIC, 2006).

Grande parte das referências que estudam o uso de AM no monitoramento de máquinas têm enfoque na tarefa de diagnóstico. Há na Universidade Federal do Espírito Santo (UFES) um grupo que desde 2007 estuda, em parceria com a Petrobrás, sistemas de reconhecimento de defeitos em motobombas. Alguns destes trabalhos serão apresentados a seguir, para que se demonstre a evolução do grupo até uma abordagem centrada na seleção de características.

Outro conjunto de referências busca explicitar como foi formada a base MAFAULDA e de que formas ela já foi utilizada para fins de pesquisa. A seguir, discorre-se sobre as duas sequências de estudos.

### 2.1 Núcleo NINFA da UFES

No trabalho de Loureiro (2009) selecionaram-se características do sinal de vibração a partir de 2 métodos: seleção manual com base no conhecimento de especialistas; e seleção automática dentre o conjunto ampliado de 84 características. Para o conjunto ampliado foram extraídos amplitudes de harmônicos, de harmônicos fracionados, a soma dos harmônicos, valor RMS do sinal, RMS em bandas e a energia do ruído. Após a seleção, utilizou-se o classificador dos K-vizinhos mais próximos (KNN) e a taxa de acerto foi de

90% para desbalanceamento e 81% para desalinhamento na base utilizada.

Em Wandekokem et al. (2009b) buscou-se prever a presença de desbalanceamento e de falha hidrodinâmica, enquanto em Wandekokem et al. (2009a) a presença de desalinhamento e de folga mecânica. Nos dois trabalhos aplicou-se o algoritmo de Seleção Sequencial Crescente (SFS<sup>1</sup>) para a redução do número de características. Como este algoritmo de seleção é incremental, pôde-se testar o desempenho de 70 sub-conjuntos de características. Para a avaliação destes sub-conjuntos, utilizou-se a acurácia do modelo SVM com *kernel* radial. Por fim, os autores reuniram os 20 sub-conjuntos melhor avaliados, formando um classificador *ensemble* de SVMs.

Nos trabalhos mencionados até agora o espaço de características é semelhante, contando principalmente com características do espectro de Fourier e do envelope. A partir de Boldt, Rauber e Varejão (2013), no entanto, passaram a ser avaliadas também estatísticas no tempo e na frequência e a decomposição de pacotes de Wavelet.

Note-se que nos trabalhos do grupo da UFES houve maior ênfase na construção do vetor de características do que no aumento de complexidade do classificador. Por vezes classificadores simples foram utilizados. Em Rauber et al. (2013), por exemplo, utilizaram-se os modelos 1-NN e SVM. O que se testou de fato foi o desempenho dos classificadores ao se fornecer diferentes categorias de características. Neste trabalho, além de avaliar a acurácia dos modelos, geraram-se visualizações do espaço de características ao mapeá-lo em um espaço de dimensão 2.

Resumindo esta abordagem do grupo da UFES, em Rauber, Boldt e Varejao (2015) defendeu-se que um sistema de classificação com melhor poder de discriminação é alcançado quando se extrai o máximo de informação dos sinais a princípio, e então se reduz o número de características através do algoritmo de seleção. Não há problema em se agregar características extraídas por métodos diferentes. Basta aplicar a seleção das mais relevantes para que se elimine possíveis redundâncias.

## 2.2 Utilizando a base de dados MAFAULDA

Cabe dizer que os trabalhos do grupo da UFES utilizaram dados de motobombas da Petrobrás e, mais posteriormente, dados da CWRU (2014). O presente trabalho, entretanto, se valerá da base MAFAULDA, construída a partir da bancada didática *SpectraQuest*. Devido às particularidades desta base de dados, serão apresentados a seguir trabalhos que dela se valeram.

Em Lima et al. (2013) realizam-se os primeiros testes na bancada da UFRJ. Coletou-se o total de 606 testes divididos entre condição normal, desbalanceamento e

---

<sup>1</sup> do inglês, *Sequential Forward Selection*

desalinhamentos vertical e horizontal. Cada cenário foi testado em 34 velocidades diferentes. Apenas 10 características foram extraídas, os 3 primeiros harmônicos nos 3 eixos de aceleração em um único mancal, mais a velocidade de rotação. Ainda assim, o classificador de rede neural multicamada (MLP) obteve 93% de acurácia.

A origem da base MAFAULDA, no entanto, remonta a Lopez (2014), que detalhou o processo de coleta dos sinais de vibração. Parte deste processo será descrito no capítulo 3. Este autor expandiu o número de características em relação aos anteriores ao coletar também os harmônicos nos 3 eixos do segundo mancal. Desta forma, foram extraídas 19 características. Após acrescentados estes sinais, o modelo melhorou sua acurácia de 88,4% para 99.1%.

Em Pestana-Viana et al. (2016) os autores extraíram também a curtose e a entropia dos sinais, com ganho de desempenho. Com apenas um mancal, esta adição aumentou a acurácia do modelo de 81.2% para 94%. Com os dois mancais monitorados, o desempenho foi de 90,1% para 99,1%. Nota-se a vantagem ao se juntar dados obtidos por diferentes técnicas, no caso oriundos do espectro da frequência e da estatística no tempo.

Em Rocha (2018) o autor realiza um estudo extensivo sobre desempenho de modelos para a base MAFAULDA. O melhor desempenho se deu para características extraídas da transformada de Wavelet, seguido pelo simples RMS dos sinais e por fim as abordagens anteriores envolvendo harmônicos e valores estatísticos. O bom desempenho utilizando apenas o RMS dos sinais é uma novidade revelada por este trabalho.

## 2.3 Conclusão

Foi feito um histórico de trabalhos relevantes em termos do uso de AM no diagnóstico de falhas rotativas. Estes trabalhos ajudam a entender formas de abordar o problema de diagnóstico, entender o que já foi tentado e o que ainda pode-se aprofundar. Nota-se que todos os trabalhos avaliam seus modelos pela métrica da acurácia, e alguns pela área da curva ROC (AUC). Estas métricas são importantes para quantificar e comparar o desempenho modelo. No entanto, relativamente pouca atenção foi dada à interpretação dos dados, do modelo e das previsões. Será preocupação deste trabalho fazer avaliações sobre a base de dados e sobre as características com maior poder de classificação entre os defeitos ensaiados.

## 3 Descrição dos dados


O trabalho usará a base de dados *Machinery Fault Database* (MAFAULDA, 2017). Ela consiste em uma coleção de sinais de vibração gerados a partir de 1951 testes na bancada de ensaios da *SpectraQuest*. Neste capítulo serão descritas a construção e a composição desta base de dados.

### 3.1 Bancada de vibração e instrumentação

Bancadas de vibração têm um importante papel no contexto acadêmico. É a partir delas que normalmente ocorre o primeiro contato com a instrumentação de vibração. Seu uso em laboratório atende a objetivos de aprendizado, de treinamento e de pesquisa. Os conhecimentos adquiridos em laboratório são então passados para a prática profissional da medição de vibrações. Neste contexto, as vibrações são utilizadas para monitoramento, como explicado, mas também para o desenvolvimento, testagem e qualificação equipamentos e instalações.

A bancada utilizada para construção da MAFAULDA é composta pelos elementos mostrados na Figura 1. Perceba-se que o motor tem sua velocidade controlada, permitindo testes em diferentes rotações; que o torque do motor é transmitido ao eixo pelo acoplamento, que pode ser rígido ou flexível; e que o eixo apoia-se em dois mancais de rolamento enquanto suporta um ou mais rotores. O resumo das especificações é descrito na Tabela 1.

Figura 1 – Componentes da bancada.



Fonte: Lopez (2014)

Tabela 1 – Especificações da bancada (adaptada de MAFAULDA (2017))

Especificação	Valor
Motor	1/4 cv (DC)
Faixa de velocidade	700–3600 RPM
Massa do sistema	22 kg
Ø rotor	152,4 mm
Ø eixo	16 mm
Comprimento do eixo	520 mm
Distância entre mancais	390 mm
<i>Mancais</i>	
Número de esferas	8
Ø esferas	7,145 mm
Ø gaiola	28,519 mm

Os rolamentos de esfera que suportam o eixo estão montados em mancais de apoio padrão, inteiriços, parafusados à base. Sobre estes mancais estão montados os acelerômetros, instrumentos responsáveis pela medição do nível de vibração pela aceleração. No mancal interno os acelerômetros são parafusados em um bloco de alumínio fixado ao mancal, enquanto no externo um acelerômetro triaxial é montado por acoplamento magnético, conforme mostrado na Figura 2.

Figura 2 – Mancais instrumentados.

(a) Mancal interno



(b) Mancal externo



Fonte: Lopez (2014)

Os acelerômetros utilizados (Tabela 2) são do tipo piezoelétrico. Neste caso, a medição ocorre porque o cristal piezoelétrico, ao ser submetido a uma tensão mecânica, gera uma tensão elétrica proporcional. Neste processo há a transdução de vibração mecânica em excitação elétrica. Por isso dá-se ao acelerômetro o nome de transdutor de aceleração. O sinal elétrico gerado é então transmitido e coletado pela placa de aquisição.

Para a medição da velocidade de rotação do eixo, é usado como tacômetro o sensor de proximidade magnético modelo MT-190, da *Monarch Instrument*. Ele é um sensor



Tabela 2 – Especificações dos acelerômetros (adaptado de MAFAULDA (2017))

Especificação	Mancal interno	Mancal externo
Fabricante	IMI Sensors	IMI Sensors
Especificação	3x acelerômetros industriais 601A01	acelerômetro triaxial 604B31
Sensibilidade	100 mV/g $\pm 20\%$ 10,2 mV/(m/s <sup>2</sup> ) $\pm 20\%$	100 mV/g $\pm 20\%$ 10,2 mV/(m/s <sup>2</sup> ) $\pm 20\%$
Faixa de frequência	0,27—10 kHz $\pm 3$ dB	0,5—5 kHz $\pm 3$ dB
Faixa de medição	$\pm 50$ g $\pm 490$ m/s <sup>2</sup>	$\pm 50$ g $\pm 490$ m/s <sup>2</sup>

passivo e, ao ser aproximado de um material ferroso a uma certa velocidade, gera sinais de tensão proporcionais. O sensor está conectado a um amplificador que transforma estes sinais em pulsos sincronizados com a rotação do eixo. Para que haja a captação, afixa-se ao eixo um objeto ferroso. Deve-se também garantir uma aproximação mínima de 6,35 mm entre o eixo e o sensor. Assim como no caso dos acelerômetros, o pulso gerado é transmitido e coletado pela placa de aquisição.

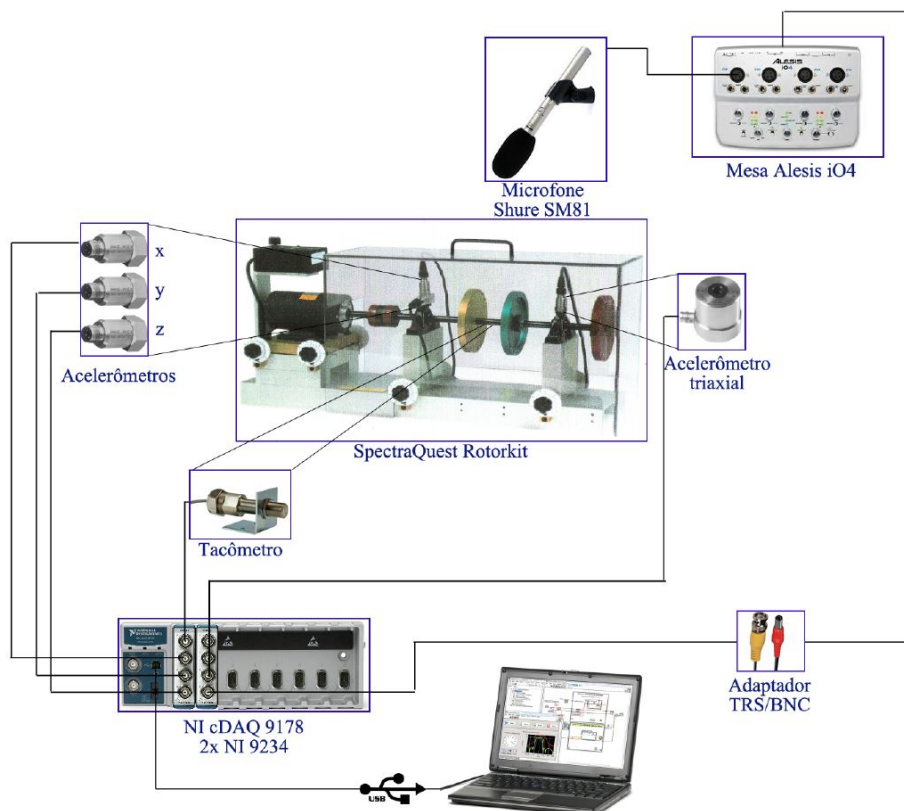
O último sensor utilizado é um microfone condensador Shure SM81, com resposta de frequência de 20 Hz a 20 kHz. Ele capta o som gerado pela máquina e se encontra a uma distância de 10 cm do rotor. A interface de áudio Alesis iO4 fornece ao microfone a necessária alimentação de 48 V, e gera o sinal de saída. Apesar de ter sido captado, o sinal do microfone não será aproveitado neste trabalho, que enfoca especificamente nos sinais de vibração.

Todos os sensores mencionados estão conectados à placa de aquisição. Nela ocorre a transformação dos sinais analógicos em sinais digitais. A placa utilizada nos ensaios é a NI 9234 da *National Instruments*, que possui 4 canais de entrada e opera a uma taxa de aquisição de até 51,2 kHz/canal. Foram utilizadas 2 placas para os 8 sinais coletados. Estas placas estão conectadas ao chassi NI cDAQ 9178, que fornecer a alimentação de energia e realiza a conexão delas com o computador pela interface USB. No computador, se realiza o processamento, a exibição e a gravação do sinal. Em resumo, a instrumentação utilizada para a construção da base MAFAULDA é descrita no diagrama da Figura 3.

No computador, as medições foram configuradas no *software* NI LabVIEW e registradas em arquivos de texto. Nesses arquivos, os sinais estão divididos em 8 colunas na seguinte ordem: (1) tacômetro; acelerações no mancal interno a cada eixo (2) axial, (3) radial e (4) tangencial; acelerações no mancal externo a cada eixo (5) axial, (6) radial e (7) tangencial; e (8) microfone. Os 6 eixos mencionados com medição de aceleração vibracional são mostrados conforme Figura 4.

Todas as medições são realizadas com a duração de 5 segundos a uma frequência


Figura 3 – Instrumentação da bancada.



Fonte: Lopez (2014)

de amostragem de 50 kHz, totalizando 250.000 amostras por sinal. Para cada defeito foram feitos ensaios com diferentes níveis de severidade e a diferentes rotações. Para cada severidade realizaram-se ensaios em até 50 rotações, variando na faixa de operação da bancada (11,7 — 60 Hz). Mais informações sobre os ensaios e a instrumentação utilizada podem ser encontradas no trabalho Lopez (2014) e no site da base MAFAULDA (2017). Neste site pode-se baixar uma cópia dos dados de todos os ensaios realizados.

Figura 4 – Eixos de medição.



Fonte: Lopez (2014)

## 3.2 Falhas simuladas e suas assinaturas

Dito de maneira simples, vibração é movimento oscilatório de uma máquina ou de suas partes em torno do seu ponto de equilíbrio (GIRDHAR; SCHEFFER, 2004). Em máquinas rotativas, o próprio movimento fornece energia para a vibração. Quando a máquina está em boas condições, o nível da vibração é mantido baixo e constante. No entanto, havendo danos ou desajustes, a máquina passará a vibrar com maior intensidade e o próprio sinal a apresentar padrões característicos ao defeito manifestado. A esses padrões no sinal de vibração chamamos assinatura da vibração (LOUREIRO, 2009).

A um movimento oscilatório podemos associar o conceito de frequência. Medida em Hertz (Hz), ela traduz o número de ciclos completos por segundo. Conjuntos simples, como o modelo massa mola, possuem um único componente de frequência associado à sua vibração. O mais comum, no entanto, é encontrar sistemas cuja vibração é descrita simultaneamente por diversas frequências. Como pode-se notar na Figura 5, a obtenção dessas componentes dificilmente se realiza pela simples observação do sinal no tempo. Para tal tarefa, dispõe-se da Transformada de Fourier, ferramenta matemática capaz de descrever completamente o sinal no domínio da frequência.

Figura 5 – Transformada de Fourier para a identificação dos componentes em frequência.



Fonte: Autoria própria


A seguir, são descritos os diferentes ensaios realizados, como foi feita a inserção de defeitos e o que a literatura tradicional de análise de vibrações apresenta como indicadores destes defeitos no domínio da frequência.

### 3.2.1 Desbalanceamento

Vibração por desbalanceamento é provavelmente um dos defeitos de máquina mais comuns. Desbalanceamento é a condição que existe em um rotor quando uma força ou movimento de vibração é a ele impetrado e aos seus mancais por forças centrífugas de excentricidades de massas (ISO, 2017). Ou seja, ele ocorre quando há desencontro entre o centro de massa e o eixo do rotor, geralmente causado por algum desgaste, encrustamento, dano ou defeito de fabricação localizado e assimétrico radialmente. Na Figura 6a há um

exemplo de excentricidade de massa  $m$  que, a uma distância  $d$  do centro de rotação, causa uma força de desbalanceamento  $U = md\omega^2$  mostrada na Figura 6b. Note-se que esta força é proporcional também ao quadrado da rotação  $\omega$  e que, por haver apenas uma excentricidade centrada em relação ao eixo, trata-se de um desbalanceamento estático.

Figura 6 – Causa do desbalanceamento.



Fonte: PRÜFTECHNIK (2011)

Nos ensaios da base MAFAULDA, a inserção do defeito de desbalanceamento foi feita ao se adicionar a massa de um parafuso e de arruelas na extremidade do rotor, que possui furos rosqueados para esse fim. A adição progressiva de arruelas permitiu a indução de desbalanceamento nos valores de 6, 10, 15, 20, 25, 30 e 35 gramas. Há no eixo apenas este rotor com desbalanceamento induzido e ele se posiciona no centro do vão entre os mancais.


O principal sintoma da presença de desbalanceamento é o pico no espectro da vibração na frequência igual à velocidade de rotação, assim como mostrado na Figura 7a. Esse pico é identificado nos eixos radial e tangencial com uma diferença de fase de cerca de  $90^\circ$  entre si. No entanto, no caso do desbalanceamento estático, os picos ocorrem em fase quando se considera o mesmo eixo nos dois mancais de apoio, conforme ilustrado na Figura 7b. Por essa característica, considerar os harmônicos obtidos a partir da transformada de Fourier dos sinais de vibração mostra-se uma ferramenta interessante para a classificação desse tipo de defeito.

### 3.2.2 Desalinhamento horizontal

São realizados ensaios para duas categorias de desalinhamento paralelo, o horizontal e o vertical. Para que o defeito seja transmitido ao eixo e tenha impacto na vibração nos mancais, um acoplamento rígido foi instalado na ligação do motor ao eixo.

O desalinhamento horizontal foi induzido alterando-se a posição do motor. Isto foi possível graças a parafusos de ajuste presentes na lateral da bancada para este fim.

Figura 7 – Diagnóstico do desbalanceamento.

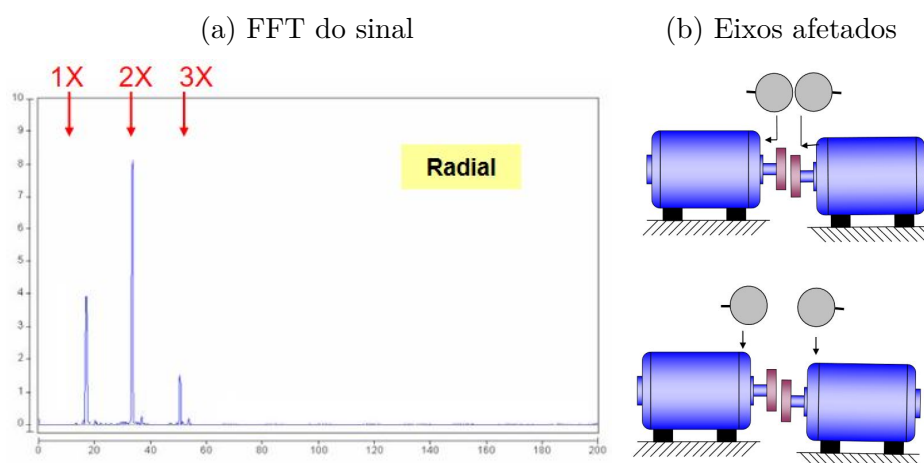


Fonte: PRÜFTECHNIK (2011)

Deslizando a base do motor lateralmente e fixando a posição com os parafusos, diferentes posições foram ensaiadas, no caso desalinhamentos de 0,5; 1; 1,5; e 2 mm.

O desalinhamento paralelo é acusado por altos níveis de vibração nos três primeiros múltiplos da frequência de rotação nos eixos radial e tangencial, conforme Figura 8a. Quando o desalinhamento é severo, pode haver múltiplos harmônicos de maior ordem, mas ao contrário de defeitos como folgas mecânicas, não ocorre carpete de ruído fora dos picos. A presença de outros picos pode ter como causa o tipo e o material do acoplamento. Na Figura 8b ilustram-se os eixos afetados pelo desalinhamento paralelo.

Figura 8 – Diagnóstico do desalinhamento paralelo.



Fonte: PRÜFTECHNIK (2011)

Em todos os eixos há mudança de fase de cerca de  $180^\circ$  nas duas extremidades do acoplamento. No entanto, a mudança de fase indicada não será detectada a partir dos dados da base MAFAULDA conquanto não há nela dados de vibração no mancal do motor.

Há também uma mudança de fase de  $0^\circ$  ou de  $180^\circ$  entre os eixos radial e tangencial (SKF Condition Monitoring, 1994).

Outra técnica utilizada para a detecção de desalinhamento é a captação do movimento orbital do eixo. No entanto esta técnica depende do uso de 2 sensores de proximidade em posição ortogonal, medindo o deslocamento do eixo (MONTE; VERBELEN; VERVISCH, 2014; GOLDMAN; MUSZYNSKA, 1999). Devido à ausência desses sinais, não se usará desta técnica neste trabalho.

### 3.2.3 Desalinhamento vertical

O desalinhamento vertical foi provocado pela inserção de calços entre o motor e a sua base. São quatro pontos de apoio parafusados. Portanto, foram adicionados calços nos quatro pés a cada etapa, mantendo o motor paralelo em relação à posição original. O desalinhamento foi ajustado em seis diferentes níveis: 0,51; 0,63; 1,27; 1,4; 1,78; e 1,9 mm.

O diagnóstico de desalinhamento vertical é dado de maneira semelhante ao caso horizontal, dado que ambos são casos de desalinhamento paralelo. Não foi encontrada na literatura de análise de vibrações a diferenciação dos dois casos. Caberá ao modelo de AM identificar as distinções entre as duas condições, a partir do cruzamento de dados nos diferentes eixos.

## 3.3 Resumo

Na Tabela 3 encontra-se o resumo da distribuição do número de ensaios realizados por categoria de defeito induzido.

Tabela 3 – Quantidade de ensaios por defeito inserido (adaptada de MAFAULDA (2017))

Classes	Qtde. de ensaios
Normal	49
Desbalanceamento	333
Desalinhamento horizontal	197
Desalinhamento vertical	301
Total	880

## 4 Extração de características

O sinal de vibração é um dado não estruturado, extenso e redundante demais para ser utilizado em modelos AM convencionais. É interessante obter valores que indiquem, de modo agregado, as diferentes características de um sinal de vibração. Existem na literatura diversas características descritivas para avaliar sinais de vibração. Algumas oferecem maior, enquanto outras oferecem menor sucesso na tarefa de classificação de falhas. Neste capítulo serão apresentadas características extraídas através de duas técnicas de processamento de sinais. Serão avaliadas características extraídas diretamente do espectro — a amplitude na frequência de rotação, harmônicos e ângulos de fase — e outras extraídas das estatísticas no tempo e na frequência. Antes disso, será exposta uma medida de precaução tomada antes do processamento da base de dados.

### 4.1 *Downsampling* dos sinais de vibração

A primeira precaução tomada com relação à base de dados diz respeito à frequência de aquisição utilizada nos ensaios. O limite superior para esse valor deve ser ditado pelo acelerômetro utilizado e o acoplamento existente entre ele e o mancal (IMI SENSORS, 2019). Enquanto os acelerômetros do mancal interno são montados por rosqueamento e permitem leituras de até 10 kHz, o acelerômetro triaxial externo é montado em base magnética e realiza leituras adequadas até a faixa de 5 kHz. Na base MAFAULDA, no entanto, a captação da vibração foi realizada próximo ao máximo permitido pela placa de aquisição, na frequência de amostragem  $F_s = 50$  kHz.


Ao se realizar leituras a uma frequência de amostragem acima do recomendado pelo manual dos acelerômetros, corre-se o risco de obter medições de fenômenos de alta frequência distorcidos e que não guardam relação com a vibração do sistema. É recomendado, portanto, reduzir a taxa de amostragem, tomando o cuidado de, antes disso, realizar a filtragem do sinal para evitar o efeito do *aliasing*. Na Figura 9 nota-se o efeito da redução da frequência de amostragem por 10 vezes.

### 4.2 Análise do espectro

A extração de características no espectro depende da correta análise de Fourier. Antes de se apresentar as características extraídas, será apresentado o procedimento de obtenção do espectro dos sinais de vibração.

A Transformada Discreta de Fourier (DFT) é a transformada específica para sinais

Figura 9 – Redução da frequência de amostragem.



Fonte: Próprio autor

digitais finitos (COOLEY; LEWIS; WELCH, 1969). Nela, transforma-se o sinal no tempo  $x[n]$  de comprimento  $N$  para o seu correspondente na frequência  $X[k]$  a partir da equação

$$X[k] = \frac{1}{N} \sum_{n=0}^{N-1} x[n] \cdot e^{-jk \frac{2\pi}{N} n}. \quad (4.1)$$

Note que de série de valores  $x[n]$  só adquire dimensão temporal a partir do valor da taxa de amostragem  $F_s$ , dada em Hertz. O instante de ocorrência de cada valor é fornecido então pelo vetor  $t[n] = n \cdot 1/F_s$  em segundos. Da mesma forma para o domínio da frequência (CERNA; HARVEY, 2000), as frequências em Hertz presentes na transformada  $X[k]$  só são identificadas a partir do vetor

$$f[k] = \frac{k}{N} \cdot F_s, \quad k \in \{0, 1, 2, \dots, N/2\}. \quad (4.2)$$

Tanto para  $X[k]$ , quanto para  $f[k]$  tomam-se índices até  $N/2$  para a análise de frequência, metade do comprimento da transformada. Isto porque a DFT do sinal gera uma sequência simétrica de valores e a partir desse índice não há mais ganho de informação. Além disso, a maior valor representado no vetor  $f[k]$  é a frequência de Nyquist, que equivale a  $F_s/2$ . Ela corresponde à máxima frequência que pode estar presente em um sinal amostrado sem reprodução de erro. Dito de outra forma, qualquer componente de frequência presente no sinal amostrado deve estar abaixo da frequência de Nyquist, ou então deve ser filtrado durante a captação, sob o risco de produzir erros de *aliasing* (LEIS, 2011, p. 82).


Por fim, um método muito mais eficiente de se calcular a DFT é pela Transformada Rápida de Fourier (FFT), um algoritmo otimizado e aplicado em diversas soluções pela sua vantagem computacional (BRIGHAM, 1988). Portanto, ao longo do trabalho se utilizará a FFT para a obtenção do espectro dos sinais.



### 4.2.1 Frequência de rotação

Obter a velocidade de rotação do eixo é fundamental para a representação do sistema e até para a posterior extração dos harmônicos. O sinal do tacômetro serve justamente para este fim. Ele é composto por um sinal que se repete em sincronia a cada rotação do eixo, como mostrado na Figura 10a para um sinal com período de 0,03 s. A frequência de repetição desse sinal é obtida pelo primeiro pico no espectro do tacômetro, mostrado na Figura 10b. Note que o segundo pico é inclusive maior que o primeiro pico. Para a obtenção correta da frequência de rotação, será adotado procedimento semelhante àquele utilizado por Lima et al. (2013) e por Ribeiro (2018).

Figura 10 – Sinal do tacômetro a uma rotação de 32,8 Hz.



Fonte: Próprio autor

Primeiro, toma-se a transformada do sinal do tacômetro e obtém-se o índice  $k_i$  onde se localiza o maior pico em amplitude. Registra-se a frequência  $f_i = f[k_i]$  correspondente a este índice no vetor pela Equação 4.2. Obtido o valor do pico no tacômetro, ele e os valores ao seu redor, no intervalo  $k_i - 3 \leq k \leq k_i + 3$ , são igualados a zero e procede-se com a busca do próximo pico no espectro do tacômetro. Esse procedimento é repetido 3 vezes, gerando os candidatos  $f_1$ ,  $f_2$  e  $f_3$ . A velocidade de rotação é o menor valor entre os candidatos, ou seja,

$$f_r = \min\{f_1, f_2, f_3\} . \quad (4.3)$$

### 4.2.2 Componentes harmônicos

Considerando as assinaturas de defeitos apontadas na seção 3.2, outra característica relevante na identificação de defeitos é a amplitude do espectro na frequência de rotação e nos seus harmônicos. A extração destas amplitudes é direta, buscando em cada transformada o valor correspondente à rotação  $f_r = f[k_r]$  e seus múltiplos.

Há, no entanto, um cuidado a se tomar. A resolução em frequência do espectro é limitada pela duração do ensaio  $\Delta t_{ensaio}$  (HARRIS; PIERSOL, 2002, p. 22.17), em

particular

$$\Delta f = \frac{F_s}{N} = \frac{1}{\Delta t_{ensaio}}. \quad (4.4)$$

Portanto, para ensaios de 5 segundos de duração, o espectro dos sinais possui uma resolução de 0,2 Hz, impactando na incerteza do valor obtido para  $f_r$ . Essa incerteza acaba sendo propagada na determinação da frequência dos harmônicos. Por isso, busca-se o pico de amplitude em torno das posições  $X[k_r]$ ,  $X[2k_r]$  e  $X[3k_r]$  esperadas para estes harmônicos, dentro de uma faixa arbitrariamente pequena. É realizada a extração dos 3 primeiros harmônicos em cada sinal. Como são 6 sinais de vibração por ensaio, têm-se 18 características desse tipo no total.

### 4.2.3 Ângulos de fase

O resultado da transformada 4.1 é uma sequência complexa. Normalmente se denomina espectro da frequência o valor absoluto  $|X[k]|$  da transformada. Já o componente angular é importante na aproximação da diferença do ângulo de fase  $\phi$  entre dois sinais  $x_1$  e  $x_2$ , especialmente no índice da frequência de rotação  $k_\omega$  (KAY, 1993, p. 532). Seu cálculo é dado pela diferença do componente angular da transformada dos dois sinais, ou, usando álgebra complexa, pela divisão

$$\phi = \angle X_1[k]/X_2[k]. \quad (4.5)$$

Na seção 3.2 são mencionadas assinaturas de vibração também para o ângulo de fase entre os sinais. Embora se almeje a diferença de fase entre eixos específicos, serão tomadas as fases dos 6 sinais de vibração em relação ao sinal do tacômetro. Diferenças específicas entre eixos serão resolvidas posteriormente, dado que o modelo de aprendizado de máquina pode realizar transformações lineares. São 6 sinais, originando 6 ângulos de fase dados pela equação 4.5 avaliada no índice  $k_r$  da frequência de rotação.


Outra possibilidade levantada é a de que os ângulos de fase mapeados linearmente no intervalo  $(-\pi, \pi]$  não seja uma boa representação do valor de fase. Por isso, será testado também o mapeamento de cada ângulo nos seus valores de seno e cosseno, gerando 12 novas características.

## 4.3 Valores estatísticos

Outro conjunto de características com relevância para a identificação de padrões em sinais de vibração são os valores estatísticos que eles produzem. Como exemplo, mostra-se na Figura 11 um fragmento dos sinais no tempo de um dos experimentos. À direita da figura, os histogramas representam a distribuição das amostras registradas em cada sinal.

Percebe-se que cada sinal possui uma distribuição distinta e em faixas de valores distintos. Essas distinções podem ser parcialmente capturadas pelos valores estatísticos.

Figura 11 – Sinais no tempo e histogramas por eixo, para um caso de 35g de desbalanceamento a 32,8 Hz de rotação.



Fonte: Autoria Própria

Em Xia et al. (2012), foi utilizada para a extração de características uma coleção de valores estatísticos dos sinais no tempo e na frequência. Essa coleção foi utilizada novamente por Rauber, Boldt e Varejao (2015) e é exposta na Tabela 4.

Os valores da Tabela 4 serão descritos a seguir, de acordo com seus subscritos. Do sinal no tempo, foram extraídos: o valor efetivo (RMS) e a raiz quadrada da amplitude (SRA), capturando a energia e a variabilidade contida do sinal; o terceiro e o quarto momentos estatísticos, respectivamente os valores de assimetria (SV) e de curtose (KV); a amplitude máxima do sinal pelo valor pico-a-pico (PPV); e outras características adimensionais, como os fatores de crista (CF), de impulso (IF), de margem (MF), de formato (SF) e de curtose (KF). Acrescentou-se a esses parâmetros a entropia  $\mathcal{H}$ , que é uma medida da aleatoriedade ou imprevisibilidade de uma variável aleatória (PESTANA-VIANA et al., 2016). Ela será aproximada com base nas probabilidades  $P(x)$  dada pelas faixas no histograma dos sinais.

Além das estatísticas no domínio do tempo, há as do domínio da frequência, calculadas com base na FFT dos sinais. Serão calculados valores na unidade de frequência, quais sejam a frequência central (FC), a frequência RSM (RMSF) e a raiz da variância da

Tabela 4 – Estatísticas dos sinais no tempo  $x[i]$  e na frequência  $X[i]$  (adaptada de Rauber, Boldt e Varejao (2015) e Xia et al. (2012))

Domínio do tempo	
$x_{rms} = \left( \frac{1}{N} \sum_i^N x_i^2 \right)^{1/2}$	$x_{sra} = \left( \frac{1}{N} \sum_i^N \sqrt{ x_i } \right)^2$
$x_{sv} = \left( \frac{1}{N} \sum_i^N \frac{x_i - \bar{x}}{\sigma} \right)^3$	$x_{kv} = \left( \frac{1}{N} \sum_i^N \frac{x_i - \bar{x}}{\sigma} \right)^4$
$x_{ppv} = \max_i(x) - \min_i(x)$	$x_{cf} = \frac{\max_i( x )}{x_{rms}}$
$x_{if} = \frac{\max_i( x )}{\frac{1}{N} \sum_i^N  x_i }$	$x_{mf} = \frac{\max_i( x )}{x_{sra}}$
$x_{sf} = \frac{x_{rms}}{\frac{1}{N} \sum_i^N  x_i }$	$x_{kf} = \frac{x_{kurt}}{x_{rms}^4}$
$\mathcal{H} = - \sum_i^N P(x_i) \log P(x_i)$	
Domínio da frequência	
$f_{fc} = \sum_i^N f_i \cdot X_i / \sum_i^N X_i$	$f_{rmsf} = \left( \sum_i^N f_i^2 \cdot X_i / \sum_i^N X_i \right)^{1/2}$
$f_{rvf} = \left( \sum_i^N (f_i - f_c)^2 \cdot X_i / \sum_i^N X_i \right)^{1/2}$	

frequência (RVF), todos também presentes na Tabela 4.

#### 4.3.1 Vetor de características

Por fim, o vetor de características gerado possui no total 121 características extraídas pelas diferentes técnicas descritas. O resumo quantitativo é fornecido na Tabela 5.

Tabela 5 – Quantidade de características por grupos.

Tipo	Características	Qtde.
—	Rotação	1
Espectro	3 Harmônicas	18
	Ângulos de fase	6
	Seno e cosseno da fase	12
Estatístico	Estatísticas no tempo	66
	Estatísticas na frequência	18
<i>Total</i>		121

## 5 Aprendizado de máquina supervisionado


O aprendizado de máquina (AM) é o emprego de algoritmos que visam otimizar um critério de desempenho usando dados de exemplo ou experiências anteriores (AYODELE, 2010). A tarefa realizada por algoritmos de AM pode ter finalidade preditiva, buscando inferir valores futuros, ou descritiva, para se ganhar conhecimento dos dados. Usa-se teoria estatística para a construção de modelos matemáticos, pois sua principal tarefa é realizar inferência a partir de dados.

A tarefa de diagnóstico de defeitos realizada neste trabalho cai na categoria de aprendizado supervisionado, quando a variável de resposta é conhecida e cada dado de treinamento é rotulado. De forma geral, há um conjunto de treinamento com  $n$  dados rotulados na forma  $(\mathbf{x}_i, y_i)$ , onde cada  $\mathbf{x}_i$  representa um exemplo e cada  $y_i$  o seu rótulo. Em uma tarefa de classificação, esta variável de resposta é discreta e indica a qual classe a cada exemplo pertence (LORENA; CARVALHO, 2007).

Com este conjunto de dados, deve-se produzir um classificador, também denominado modelo, preditor ou hipótese, capaz de prever o rótulo para dados novos, não contidos no conjunto de treinamento. Portanto, esse processo de obtenção do classificador ocorre por indução e denomina-se treinamento do modelo. O modelo gerado comporta-se como uma função  $f$ , a qual mapeia um dado de entrada  $\mathbf{x}$  até uma predição  $y$ .

Cada exemplo  $\mathbf{x}_i$  é geralmente representado por um vetor de características, onde cada característica é considerada uma variável livre que colabora na previsão do modelo. Na Figura 12 se exemplifica uma base de dados com  $n$  exemplos, cada exemplo contendo  $m$  características (ou atributos).

Figura 12 – Aprendizado supervisionado.



Fonte: Lorena e Carvalho (2007)

A previsão gerada pelo modelo está sempre sujeita a erros. Durante o treinamento busca-se a redução da função custo para o erro, calculada com base nos dados rotulados. Realizam-se ajustes nos parâmetros do modelo até que se atinja um mínimo da função custo,

um mínimo local ou absoluto a depender da função (SIMEONE, 2017, p. 114). A avaliação dos erros de classificação se dá após o treinamento, na forma de métricas específicas, conforme detalhado a seguir na seção 5.2. Por fim, estas métricas serão utilizadas na comparação de desempenho de diferentes modelos.

Ressalta-se que uma grande vantagem do modelo gerado é o poder de análise massivo. Após treinado e validado, o modelo pode avaliar grandes volumes de sinais com agilidade e eficiência. Outra vantagem é o alcance da análise. Enquanto a capacidade de visualização humana geralmente permite acompanhar indicadores — numéricos ou gráficos — em até três dimensões em simultâneo, não há limite ao número de dimensões que um modelo pode analisar e às quais pode se ajustar a partir das técnicas de AM. Com eles, alcançam-se padrões que só podem ser encontrados em espaços multidimensionais.

As opções de modelo classificados são variadas, mas neste trabalho se optará pela máquina de vetores-suporte (SVM<sup>1</sup>). Esse é um modelo amplamente usado no diagnóstico de falhas (RAUBER; BOLDT; VAREJAO, 2015) e que possui boa capacidade de generalização.

## 5.1 Classificador máquina de vetores-suporte

Considere-se uma função  $f(\mathbf{x})$ , aplicada no vetor  $m$ -dimensional  $\mathbf{x}$ . Considere-se uma classificação de  $\mathbf{x}$  em duas classes, realizada de acordo com o sinal do resultado da função: se  $f(\mathbf{x}) < 0$  classifica-se  $C_1$ , se  $f(\mathbf{x}) > 0$  classifica-se  $C_2$ . Há nesse caso uma função de decisão direta que divide o espaço de  $\mathbf{x}$  através de uma fronteira de decisão definida por  $f(\mathbf{x}) = 0$  (ABE, 2006).

No caso do classificador linear, adequado apenas para dados linearmente separáveis, a função de decisão é da forma

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \quad (5.1)$$


onde  $\mathbf{w}$  é um vetor  $m$ -dimensional e  $b$  um escalar. Nesse caso, a fronteira de decisão é, na verdade, um hiperplano em  $\mathbb{R}^m$ .

A abordagem do SVM para o problema de classificação parte da construção de margens simétricas e paralelas em relação à fronteira de decisão. Encontrar o classificador ótimo significa então encontrar a fronteira que permita a maximização distância entre as margens, desde que não haja dados de treinamento entre elas. Na Figura 13 se exemplifica uma fronteira de decisão otimizada de acordo com o algoritmo de maximização das margens do SVM.

Geralmente para casos reais, é difícil encontrar dados ou representações que sejam linearmente separáveis. Aplicar o algoritmo SVM nesses dados sem considerar erros de

<sup>1</sup> do inglês, *Support Vector Machine*

Figura 13 – Fronteiras de decisão no plano.



Fonte: Pedregosa et al. (2011)

classificação seria inviável, porque não haveria nem separador, nem margens adequadas. Por isso, adaptou-se o algoritmo para que se aceite a classificação incorreta de alguns dos dados. Basta acrescentar ao problema de maximização um termo associado ao custo destes erros de classificação. (LORENA; CARVALHO, 2007). O problema se resume então à minimização da função

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_i \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) , \quad (5.2)$$

onde o primeiro termo corresponde à maximização da margem (pela minimização de  $\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$ ), enquanto o segundo realiza a penalização (*hinge loss*) quando há erro de classificação (PEDREGOSA et al., 2011). O hiperparâmetro  $C$  controla peso do termo de penalização do erro e pode ser ajustado de acordo com o problema.

O SVM é fundamentalmente um classificador binário. Algumas soluções foram propostas para que problemas de classificação com  $K > 2$  classes sejam resolvidos pelo algoritmo. A mais comum é a abordagem um-contra-todos. Neste caso, constroem-se  $K$  classificadores SMV diferentes e cada classificador  $k$  é treinado utilizando a classe  $C_k$  como exemplo positivo e as demais como exemplos negativos. Para que não haja classificação positiva em mais de um classe simultaneamente, costuma-se selecionar a classe com o maior valor dado pela função de decisão, ou seja, (BISHOP, 2006)

$$f(\mathbf{x}) = \max_k f_k(\mathbf{x}) . \quad (5.3)$$



## 5.2 Métricas e validação

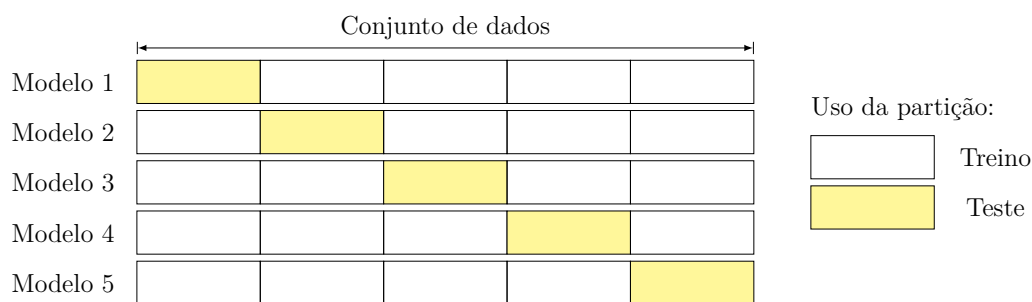
Diversas métricas podem ser utilizadas para a avaliação de desempenho do modelo. Dentre os trabalhos listados no capítulo 2, a métrica mais utilizada é a acurácia, uma métrica simples e de fácil compreensão. Ela fornece o valor em porcentagem do número de acertos em relação ao número total de exemplos testados.

Deve-se destacar que a avaliação do modelo não deve ser realizada com os mesmos exemplos que os utilizados para o seu ajuste. O objetivo do modelo gerado é obter o melhor desempenho na predição de *exemplos futuros*. Ou seja, o modelo deve alcançar um bom poder de generalização e evitar viés excessivo em relação dados de treinamento (BISHOP, 2006). Um das causas deste viés é o sobreajuste dos parâmetros do modelo, que pode ser detectada a partir das técnicas de validação descritas a seguir. Outra causa de viés ocorre devido à sub-representação dos dados de treinamento em relação à população real, alvo da predição. Esta causa, no entanto, só é identificada pela coleta de mais dados ou após a implementação prática do modelo.

Uma das técnicas para se avaliar experimentalmente o desempenho do modelo apenas com os dados disponíveis é a divisão dos dados em grupos de treino e de teste. O grupo de treino será utilizado para o ajuste do modelo, enquanto o de teste é separado apenas para a sua avaliação. Costuma-se separar de 20 a 30% dos dados para teste, amostrados com alguma forma de randomização.

Outra forma de se avaliar o modelo, em especial quando o número de exemplos é limitado, é por meio da validação cruzada (BISHOP, 2006). Formam-se  $K$  partições dos dados e realizam-se  $K$  iterações de treino e teste, separando em cada iteração a  $k$ -ésima partição para teste e o restante para treino. Ao final do processo, obtém-se medidas de desempenho para os  $K$  testes, as quais podem ser agregadas pela média e pelo desvio, por exemplo. Ilustra-se este processo na Figura 14.

Figura 14 – Validação cruzada com 5 partições ( $K = 5$ ).




Fonte: Compilação do autor

### 5.3 Fluxo de dados e *software* utilizado

A metodologia deste projeto pode ser resumida pelas etapas apresentadas na Figura 15. Parte-se da base de dados MAFAULDA (2017), gerada de acordo com o procedimento de aquisição descrito no capítulo 3. Foram obtidos 880 experimentos compostos de seis sinais de vibração e um sinal do tacômetro. Cada experimento pertence a uma das 4 categorias apresentadas na Tabela 3, quais sejam: desbalanceamento, desalinhamento vertical, desalinhamento horizontal ou condição normal, na ausência de defeitos. Desta forma, associa-se a cada experimento um rótulo  $y_i \in \{0, 1, 2, 3\}$  correspondente à sua classe.

Os sinais foram processados para a extração das características, aquelas descritas no capítulo 4. Gerou-se para cada exemplo as 121 características resumidas na Tabela 5, todas presentes no vetor  $\mathbf{x}_i$  que representa o exemplo. O produto da extração de características é, portanto, a matriz de dados  $\mathfrak{D}_{800,121}$  com 880 observações e 121 características.

Figura 15 – Etapas para a geração do classificador de falhas.



Fonte: Autoria própria

A partir deste ponto, as características são agrupadas por categoria e por eixos de origem para a realização dos testes do capítulo 6. Para cada teste, os dados foram então particionados em 8 segmentos para a realização da validação cruzada. A avaliação final para o teste é dada pela avaliação média dos 8 ciclos de treino e teste.

O projeto foi desenvolvido em Python(3.9), utilizando programas e bibliotecas de código aberto. Na etapa de extração foram utilizados os pacotes Pandas (MCKINNEY, 2010) e Numpy (HARRIS et al., 2020) para o processamento dos dados. O modelo classificador utilizado foi o LinearSVC, presente na biblioteca Scikit-learn (PEDREGOSA et al., 2011), em sua configuração padrão.

## 6 Análise dos resultados

Na primeira parte do capítulo é testada a capacidade preditora das características, agrupadas de acordo com a técnica de extração utilizada. Não foi utilizado nenhum método de otimização do modelo, o treinamento se deu a partir de modelos com a mesma configuração. Além da acurácia dos modelos, serão fornecidos exemplos que ilustrem as técnicas de extração de algumas das características.

Na segunda parte, será examinada a possibilidade de se utilizar uma menor quantidade de acelerômetros para o diagnóstico de falhas. Desta forma pode-se simplificar a instrumentação e reduzir os custos de monitoramento. Outra vantagem é a redução da dimensionalidade do modelo, que passa a ser menos complexo. Ao final de cada seção, serão apresentadas as matrizes de confusão geradas pelos modelos selecionados. Elas exibem o comportamento esperado dos modelos baseado no treino com 75% dos exemplos e teste com os 25% restantes, indicando onde ocorreram erros de classificação.

### 6.1 Desempenho por características

O desempenho do classificador varia significativamente de acordo com o dado utilizado para a previsão. Na Tabela 6 o desempenho é avaliado utilizando diferentes agrupamentos de características. É fornecida a média e o desvio padrão da taxa de acerto (acurácia) dos modelos submetidos à validação cruzada. É dado também o número de características (#Caract.) presentes em cada agrupamento.

Tabela 6 – Acurácia por grupos de características.

Tipo	Características	#Caract.	Acurácia
Espectro	Ângulos de fase	7	$0,724 \pm 0,048$
	Seno e cosseno da fase	13	$0,843 \pm 0,024$
	Harmônicas	19	$0,933 \pm 0,012$
	Harmônicas e s. c. da fase	31	$0,961 \pm 0,016$
Estatístico	RMS	7	$0,781 \pm 0,032$
	RMS, Entropia e curtose	19	$0,907 \pm 0,024$
	Estatísticas no tempo	67	$0,963 \pm 0,012$
	Estatísticas na frequência	19	$0,972 \pm 0,016$
	Estatísticas gerais	85	$0,994 \pm 0,006$
<i>Todas</i>		115	$0,994 \pm 0,006$

Foram reunidas as características extraídas nos 6 eixos de medição. A única característica compartilhada por todos os grupos, é a frequência de rotação, extraída conforme descrito na seção 4.2.1. Isto porque a rotação é um valor descritivo importante,

com impacto direto nas demais características, e pode de ser obtido com facilidade. A última consideração é que o conjunto relativo aos ângulos de fase foi descartado do conjunto total e foram considerados apenas os seus valores de seno e cosseno.

Nota-se que o aumento do desempenho do modelo parece estar associado diretamente à quantidade de características utilizadas. É possível explicar este comportamento ao se ressaltar a linearidade do modelo utilizado. Sendo linear, o modelo SVM possui baixo nível de complexidade e apresenta, por isso, menor tendência ao sobreajuste, ainda que haja um grande número de característica. Apesar da aparente dependência do desempenho do modelo em relação à abundância de características, o conjunto de estatísticas na frequência se destaca ao apresentar uma acurácia superior a 97% ainda que conte com apenas 19 características. Além este padrão geral, comentários sobre resultados específicos são realizados nas seções seguintes.

### 6.1.1 Características do espectro

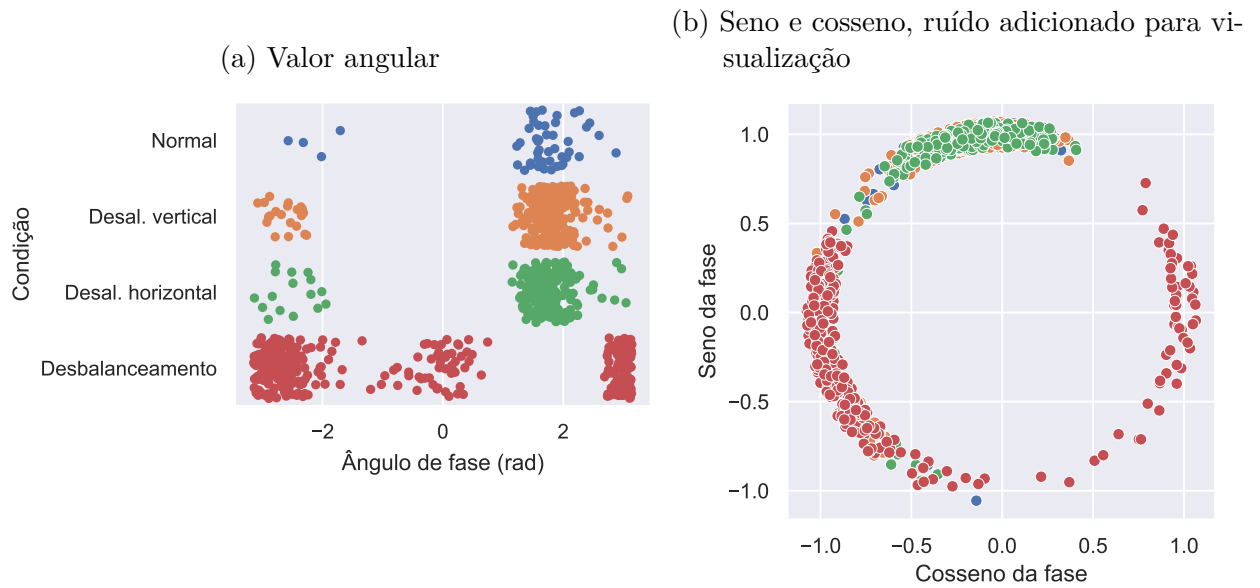
Nos primeiros testes buscou-se descobrir qual é a melhor representação dos ângulos de fase para fins de classificação de falhas. O modelo apresentou melhor desempenho quando a representação foi feita em seno e cosseno, provavelmente porque esta representação preserva o caráter cíclico da variável angular. Na Figura 16 é exemplificado como a transformação da variável facilita a separação dos exemplos. Enquanto a representação direta do ângulo gera distribuições disjuntas dos exemplos por categoria de defeito (Figura 16a), a representação em seno e cosseno produz uma clara separação entre a condição de desbalanceamento e as outras classes, a ponto de poder se discriminar essa condição apenas com as informações contidas na Figura 16b com boa taxa de acerto.

O próximo grupo de características avaliado são valores harmônicos. Eles foram extraídos com sucesso, conforme ilustrado na Figura 17 e geraram um bom resultado na para a classificação dos defeitos. Nestes gráficos, já podemos perceber algumas das características do espectro descritas na seção 3.2. Na condição normal, há a predominância do pico em 1x frequência em rotação como esperado, mas quando há defeito de desbalanceamento, este pico abre grande diferença dos demais. Na presença de desalinhamento, para os dois casos há uma presença relevante do pico em 3x a rotação.

Embora os exemplos sejam dados em uma rotação específica, pode-se visualizar o padrão geral dos picos em frequência através do gráfico em cascata. Nele exibem-se simultaneamente os ensaios em todas as velocidades. Foi adicionado no Apêndice A o gráfico em cascata para as condições mais severas de desbalanceamento e desalinhamento e para a condição normal, para fins de comparação.

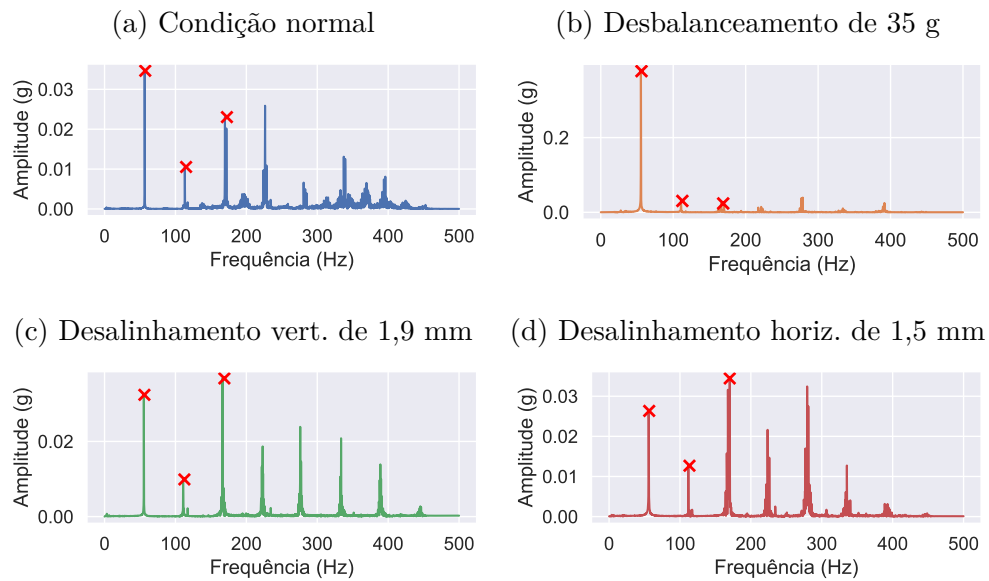
Conforme já discutido, a análise dos harmônicos é uma técnica clássica de diagnóstico de falha. A análise dos ângulos de fase é menos utilizada e se provou no trabalho

Figura 16 – Representações da fase do sinal, no eixo Tangencial 1



Fonte: Autoria Própria

Figura 17 – Espectro FFT dos sinais por categoria de defeito, à rotação de aprox. 57 Hz.



Fonte: Autoria Própria

ser menos assertiva na classificação. Há, no entanto, um ganho de desempenho quando se combina as duas técnicas de extração, mostrando complementação positiva para o poder preditivo do modelo. Esse resultado está evidenciado na Tabela 6.

Conforme mostrado na Tabela 7, a utilização das características do espectro gera um modelo que erra a classificação de mais de 5% dos exemplos normais e daqueles com desalinhamento horizontal, que acabam sendo confundidos mutuamente.

Tabela 7 – Matriz de confusão utilizando características do espectro.

Real	Predição (%)			
	Normal	Desbalanceamento	Desal. Vertical	Desal. Horizontal
Normal	91,7	0	0	8,3
Desbalanceamento	0	100,0	0	0
Desal. Vertical	0	0	100,0	0
Desal. Horizontal	6,1	0	0	93,9

### 6.1.2 Características estatísticas

Embora haja pouca literatura no assunto, técnicas de processamento de sinais baseados em valores estatísticos mostraram boa capacidade de segregação das classes para os dados da base MAFAULDA. Os testes apresentados na Tabela 6 foram realizados com a adição gradual de características, de acordo com agrupamentos já encontrados em outros trabalhos. Dessa forma pôde-se verificar como o acréscimo de informação impacta no desempenho do modelo.


Em Rocha (2018) utilizou-se apenas o valor RMS dos sinais para a classificação dos defeitos com bom desempenho, alcançando 95,38% de acurácia. No entanto, o SVM utilizado neste trabalho implementou um *kernel* de função de base radial (RBF), que projeta os dados em um espaço de características de alta dimensão e permite gerar fronteiras de decisão não lineares. Neste trabalho utiliza-se um SVM linear, que busca separações lineares dos dados. Sob essa condição de linearidade do modelo, a acurácia com o uso apenas do valor RMS foi inferior. A utilização de um modelo mais simples neste trabalho se justifica no objetivo deste trabalho, que se refere ao estudo das características utilizadas no processo de classificação e não no desenvolvimento de algoritmos complexos.

Em Pestana-Viana et al. (2016) foram avaliados modelos que utilizam os valores RMS, de curtose e de entropia. No presente trabalho, este conjunto melhorou em mais de 10% a acurácia média do modelo em relação ao que utilizava apenas o valor RMS, ultrapassando o valor de 90%. Ainda assim, uma acurácia superior a 95% foi alcançada apenas ao se adicionar as demais estatísticas no tempo, aquelas apresentadas na Tabela 4.

É notável que o uso de apenas 3 estatísticas na frequência se equipare em desempenho ao modelo treinado com as 11 estatísticas no tempo. Na Figura 18 mostra-se um exemplo de extração das estatísticas da frequência para um exemplo com desbalanceamento. O centro de frequência  $f_c$  pode ser entendido como um “centro de massa” do espectro, indicando a posição central ponderada pelos valores em amplitude. Sendo assim, componentes presentes em frequências maiores trazem o  $f_c$  para a direita, enquanto picos em baixas frequências o traz à esquerda do espectro.

O modelo gerado a partir das características estatísticas tem dificuldade apenas na

Figura 18 – Espectro dos sinais no primeiro mancal e posição do centro de frequência, para um caso de 35g de desbalanceamento a 32,8 Hz de rotação.



Fonte: Autoria Própria

identificação do desalinhamento vertical, conforme apontado na Tabela 8. Ainda assim, são erros que juntos não formam 5% dos exemplos e acabam sendo classificados nos outros dois tipos de falha.

Tabela 8 – Matriz de confusão utilizando características estatísticas.

Real	Predição (%)			
	Normal	Desbalanceamento	Desal. Vertical	Desal. Horizontal
Normal	100,0	0	0	0
Desbalanceamento	0	100,0	0	0
Desal. Vertical	0	1,3	96,1	2,6
Desal. Horizontal	0	0	0	100,0


### 6.1.3 Resumo

A comparação de desempenho dos diferentes grupos de características pode ser realizada graficamente na Figura 19. Esta figura apresenta, para cada teste, a distribuição da acurácia obtida na validação cruzada. A cor das caixas indica se as características foram extraídas diretamente do espectro ou das estatísticas.

Nota-se que o agregado de características estatísticas acabaram tendo um desempenho melhor do que aquelas extraídas diretamente do espectro, as harmônicas e os ângulos de fase transformados. A relevância preditiva dos valores estatísticos é tão prevalente que a acurácia do modelo nem sequer se altera após a adição das características do espectro.

Ao se utilizar todas as características, o modelo continua com dificuldade apenas na classificação do desbalanceamento vertical, assim como mostrado na Tabela 9. Os erros, no entanto, não somam sequer 3% dos casos.

Figura 19 – Box-pot da acurácia por grupos de características.



Fonte: Autoria Própria

Tabela 9 – Matriz de confusão utilizando todas as características.

Real	Predição (%)			
	Normal	Desbalanceamento	Desal. Vertical	Desal. Horizontal
Normal	100,0	0	0	0
Desbalanceamento	0	100,0	0	0
Desal. Vertical	1,3	0	97,4	1,3
Desal. Horizontal	0	0	0	100,0

## 6.2 Desempenho por eixos de medição

Pode-se avaliar também o desempenho do modelo quando há limitação na quantidade de sinais disponíveis. Há na base MAFAULDA seis sinais de vibração, uma configuração possivelmente redundante e excessiva comparado a dados de máquinas em produção.

É apresentado na Tabela 10 o desempenho do classificador quando se extraem todas as características mencionadas, mas apenas a partir do sinal em eixos específicos. Nas primeiras linhas e colunas, a configuração se limita a apenas 1 único acelerômetro. Em nenhum destes casos uma acurácia média maior do que 90% foi alcançada. Na última linha há junção dos sinais dos três eixos para cada mancal, como se houvesse um acelerômetro triaxial acoplado ao mancal interno ou ao externo. Já na última coluna, se avalia a




instalação de acelerômetros em pares, na mesma direção, mas em mancais diferentes. Em destaque, as configurações com melhor desempenho.

Tabela 10 – Acurácia por eixos de medição selecionados.

	Mancal 1 interno	Mancal 2 externo	Mancais 1 e 2
Axial	$0,852 \pm 0,024$	$0,869 \pm 0,028$	$0,956 \pm 0,018$
Radial	$0,889 \pm 0,023$	$0,830 \pm 0,027$	<b><math>0,986 \pm 0,010</math></b>
Tangente	$0,823 \pm 0,039$	$0,887 \pm 0,016$	$0,943 \pm 0,019$
Triaxial	<b><math>0,989 \pm 0,008</math></b>	$0,970 \pm 0,016$	$0,993 \pm 0,008$

O desempenho por eixos também pode ser analisado a partir da Figura 20. Enquanto a configuração com os 6 sinais continua obtendo o melhor desempenho, acurácias também elevadas seriam alcançadas pelo uso de um acelerômetro triaxial no mancal interno, ou pelo uso de um par de acelerômetros na direção radial, um em cada mancal. Estas 2 configurações são analisadas mais profundamente nas Tabelas 11 e 12.

Figura 20 – Box-pot da acurácia por eixos.



Fonte: Autoria Própria

Tabela 11 – Matriz de confusão para acelerômetro triaxial no mancal interno.

Real	Predição (%)			
	Normal	Desbalanceamento	Desal. Vertical	Desal. Horizontal
Normal	100,0	0	0	0
Desbalanceamento	0	100,0	0	0
Desal. Vertical	0	0	98,7	1,3
Desal. Horizontal	0	2,0	6,1	91,8

Tabela 12 – Matriz de confusão para pares de acelerômetros radiais.

Real	Predição (%)			
	Normal	Desbalanceamento	Desal. Vertical	Desal. Horizontal
Normal	100,0	0	0	0
Desbalanceamento	0	98,8	1,2	0
Desal. Vertical	1,3	1,3	96,1	1,3
Desal. Horizontal	2,0	0	0	98,0

Nota-se na configuração triaxial da Tabela 11 alguma dificuldade na classificação do desalinhamento horizontal, que pode ser classificado erroneamente como desalinhamento vertical em mais de 5% dos casos. Na configuração da Tabela 12 há erros de classificação mais dispersos, mas em valores menores.

### 6.3 Conclusão

Este capítulo apresentou o desempenho do classificador SVM linear quando exposto a diferentes subconjuntos de características. Notou-se o desempenho superior de modelos baseados em características estatísticas, em particular quando há a combinação de estatísticas do domínio da frequência e do tempo. Esta combinação é suficiente para classificar corretamente cerca de 99% dos dados, sem que haja a necessidade de se utilizar as características harmônicas e de fase.

Com relação à análise dos eixos de medição, notou-se que há espaço para a redução do número de sensores. Utilizar o sinal de apenas um sensor não apresentou desempenho satisfatório, independentemente do sensor selecionado, pois em todos os casos houve erro de classificação em mais de 10% dos exemplos. Foram testadas combinações específicas de eixos de medição e se destacaram a configuração com medição triaxial no primeiro mancal e configuração com sensores radiais nos dois mancais. Nos dois casos, taxas de acerto superiores a 98% foram alcançadas. Abre-se, portanto, espaço para simplificação do modelo e da instrumentação.

## 7 Considerações Finais

Este capítulo apresenta as principais conclusões extraídas das análises feitas durante o desenvolvimento do trabalho e as linhas de possíveis trabalhos futuros.

### 7.1 Conclusões

Por tudo apresentado neste trabalho, podemos fazer as seguintes considerações:

- No capítulo 2 foram apresentados trabalhos que utilizam AM no diagnóstico de falhas em rotores. O aumento do número de pesquisas com este enfoque apresenta novas possibilidades à prática de manutenção preditiva. Embora existam técnicas tradicionais para a análise de vibrações e a leitura do espectro, a aplicação de algoritmos de aprendizagem pode ampliar a capacidade de supervisão e acelerar a tomada de decisão nos processos de manutenção. Modelos classificadores de falhas podem ser implementados em diferentes áreas industriais, desde que haja confiança no método, algum grau de interpretabilidade e bons resultados em testes e validações.
- Destacam-se altas taxas de acerto dos modelos testados, apresentando acurácias quase sempre superiores a 80%. O bom desempenho foi alcançado apesar da grande variação dos exemplos em relação à velocidade de rotação e à severidade do defeito induzido. Espera-se um diagnóstico de defeitos mais assertivo em rotações maiores, quando os defeitos recebem energia suficiente para manifestar suas assinaturas com mais distinção. Estas assinaturas também tendem a se tornar mais claras quando a severidade do defeito é maior. A efetividade da classificação, mesmo na ausência destas condições, aponta a alta capacidade das técnicas de AM na identificação das falhas em estudo. Vale ressaltar, porém, que os dados de treinamento e de teste foram obtidos a partir do mesmo equipamento. A generalização para a aplicação em equipamentos similares (nominalmente idênticos, mas com variabilidade de produção) não foi testada e depende de mais esforços na aquisição de dados novos.
- Alguns apontamentos puderam ser feitos em relação às características extraídas:
  - ângulos de fase dos sinais produzem classificadores lineares melhores quando mapeados a partir do seno e do cosseno;
  - características extraídas por técnicas estatísticas mostraram melhor desempenho que aquelas extraídas diretamente do espectro; e
  - em geral, quanto maior a quantidade de características, melhor o desempenho preditivo do modelo linear. No entanto, deve-se pesar o custo computacional e

o número de observações necessárias para a estimativa do modelo quando se utiliza um grande número de características.

- Foi apontada a possível redundância de informação nos 6 sinais vibração presentes na base MAFAULDA para a tarefa de classificação deste trabalho. Resultados de acurácia superiores a 98% foram obtidos utilizando apenas os 3 sinais do mancal interno, ou apenas as vibrações na direção radial dos dois mancais. Para as máquinas usadas na indústria, frequentemente haverá menos sinais disponíveis para a análise. Poderão haver ou menos acelerômetros instalados permanentemente em cada máquina, ou a aquisição de um número menor de direções para que se reduza a duração das inspeções. Como não houve perda significativa de desempenho do classificador, justifica-se a redução do número de acelerômetros, reduzindo o custo operacional do processo de monitoramento.
- Um fator importante para a realização do trabalho foi a oferta de *softwares* livres e de código aberto para projetos de AM. Bibliotecas com ampla disponibilidade de funções e de documentação também foram cruciais. No particular a este trabalho, todo o código desenvolvido encontra-se disponível no repositório [GitHub](#).

## 7.2 Trabalhos futuros

Por tudo apresentado neste trabalho, podemos fazer as seguintes propostas para continuação deste trabalho:

- Há espaço para se avaliar um número maior de técnicas extração de características. Em Barandas et al. (2020), por exemplo, há uma coleção de características que podem ser extraídas de séries temporais como os sinais de vibração e podem gerar diferentes abordagens ao problema de classificação de falhas.
- Uma das limitações dos modelos desenvolvidos é a dificuldade de interpretação das previsões que eles geram. Os modelos são capazes de realizar induções a partir de dados em altas dimensões, que vão além da capacidade de interpretação humana. Sugere-se aos trabalhos futuros desenvolver melhores interpretações para as previsões dos modelos classificadores de falha. Em Molnar (2020), por exemplo, se apresentam diferentes técnicas utilizadas para a interpretação de modelos de AM.
- Neste trabalho a classificação se restringiu às 4 classes de defeito apontadas no texto. A classificação do SVM é intrinsecamente binária e para que atendesse ao problema multiclasse do trabalho, utilizou-se a abordagem um-contra-todos. Sugere-se o estudo de algumas das classificações binárias que possam responder, por exemplo, quais características melhor diferenciam a condição normal das condições de falha, ou quais segregam melhor o desalinhamento horizontal do vertical.

- Em relação à base MAFAULDA, apesar haver grande variação de velocidades e de severidades para cada categoria de defeito, há pouca diversidade em relação ao sistema mecânico. Sugere-se, na disponibilidade de bancadas de vibração, a montagem de bases de dados complementares em que hajam mais condições de falha — como desbalanceamento dinâmico, motores defeituosos, desalinhamento angular, etc. — ou diferentes configurações mecânicas variando, por exemplo, a distância entre mancais, o diâmetro do eixo, ou o acoplamento. Outra possibilidade é a adição de elementos de máquinas como polias, freios ou engrenagens, ou máquinas como bombas e ventiladores ao sistema rotativo. Desta forma pode-se aproximar a variabilidade dos dados de vibração àquela encontrada nas aplicações na indústria.

## Referências

- ABE, S. *Support Vector Machines for Pattern Classification*. [S.l.]: Springer Science & Business Media, 2006. Citado na página 30.
- ABRAMAN. *Documento Nacional – A situação da Manutenção no Brasil*. 2017. Citado na página 8.
- AYODELE, T. O. Introduction to machine learning. *New Advances in Machine Learning*, InTech, p. 1–9, 2010. Citado na página 29.
- BARANDAS, M. et al. Tsfel: Time series feature extraction library. *SoftwareX*, v. 11, p. 100456, 2020. ISSN 2352-7110. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2352711020300017>>. Citado na página 43.
- BELLO, O.; ZEADALLY, S. Intelligent Device-to-Device Communication in the Internet of Things. *IEEE Systems Journal*, v. 10, n. 3, p. 1172–1182, set. 2016. ISSN 1932-8184, 1937-9234, 2373-7816. Disponível em: <<https://ieeexplore.ieee.org/document/6725683>>. Citado na página 9.
- BISHOP, C. M. *Pattern recognition and machine learning*. New York: Springer, 2006. (Information science and statistics). ISBN 978-0-387-31073-2. Citado 2 vezes nas páginas 31 e 32.
- BOLDT, F. D. A.; RAUBER, T. W.; VAREJÃO, F. M. A fast feature selection algorithm applied to automatic faults diagnosis of rotating machinery. *Journal of Applied Computing Research*, v. 3, n. 2, p. 78–86, dez. 2013. ISSN 2236-8434. Disponível em: <<http://revistas.unisinos.br/index.php/jacr/article/view/6834>>. Citado na página 12.
- BRIGHAM, E. O. *The fast Fourier transform and its applications*. Englewood Cliffs, N.J: Prentice Hall, 1988. (Prentice-Hall signal processing series). ISBN 978-0-13-307505-2. Citado na página 23.
- CERNA, M.; HARVEY, A. F. *The fundamentals of FFT-based signal analysis and measurement*. [S.l.], 2000. Citado na página 23.
- COOLEY, J.; LEWIS, P.; WELCH, P. The finite Fourier transform. *IEEE Transactions on Audio and Electroacoustics*, v. 17, n. 2, p. 77–85, jun. 1969. ISSN 0018-9278. Disponível em: <<http://ieeexplore.ieee.org/document/1162036/>>. Citado na página 23.
- CWRU. *Case Western Reserve University, Bearing Data Center*. 2014. Dados encontrados em <<https://csegroups.case.edu/bearingdatacenter/home>>, acessado em 01/10/2020. Citado na página 12.
- GIRDHAR, P.; SCHEFFER, C. *Practical machinery vibration analysis and predictive maintenance*. Amsterdam ; Boston : Burlington, MA: Elsevier ; Newnes, 2004. (Practical professional books from Elsevier). OCLC: ocm56694318. ISBN 978-0-7506-6275-8. Citado 2 vezes nas páginas 8 e 18.

GOLDMAN, P.; MUSZYNSKA, A. Application of full spectrum to rotating machinery diagnostics. *Orbit*, Bently Nevada Corporation USA, v. 20, n. 1, p. 17–21, 1999. Citado na página 21.

HARRIS, C. M.; PIERSOL, A. G. (Ed.). *Harris' shock and vibration handbook*. 5th ed. ed. New York: McGraw-Hill, 2002. (McGraw-Hill handbooks). ISBN 978-0-07-137081-3. Citado na página 24.

HARRIS, C. R. et al. Array programming with NumPy. *Nature*, Springer Science and Business Media LLC, v. 585, n. 7825, p. 357–362, set. 2020. Disponível em: <<https://doi.org/10.1038/s41586-020-2649-2>>. Citado na página 33.

IMI SENSORS. *Low-cost Triaxial Industrial ICP Accelerometer - Installation and Operating Manual*. [S.l.], 2019. Disponível em: <<https://www.pcb.com/products?model=604B31>>. Citado na página 22.

INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. *ISO 21940-2: Mechanical vibration — rotor balancing — part 2: Vocabulary*. Geneva, CH, 2017. Citado na página 18.

JARDINE, A. K.; LIN, D.; BANJEVIC, D. A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mechanical systems and signal processing*, Elsevier, v. 20, n. 7, p. 1483–1510, 2006. Citado na página 11.

KAY, S. M. *Fundamentals of statistical signal processing*. Englewood Cliffs, N.J: Prentice-Hall PTR, 1993. (Prentice Hall signal processing series). ISBN 978-0-13-345711-7 978-0-13-504135-2 978-0-13-280803-3. Citado na página 25.

LEIS, J. *Digital signal processing using MATLAB for students and researchers*. Hoboken, N.J.: Wiley, 2011. OCLC: 1162319970. ISBN 9781283126366. Citado na página 23.

LIMA, A. A. de et al. On fault classification in rotating machines using fourier domain features and neural networks. In: *2013 IEEE 4th Latin American Symposium on Circuits and Systems (LASCAS)*. Cusco: IEEE, 2013. p. 1–4. ISBN 978-1-4673-4900-0 978-1-4673-4897-3 978-1-4673-4899-7. Disponível em: <<http://ieeexplore.ieee.org/document/6518984/>>. Citado 2 vezes nas páginas 12 e 24.

LOPEZ, R. Z. *Classificação automática de defeitos em máquinas rotativas*. Tese (Doutorado) — UFRJ, 2014. Disponível em: <<http://monografias.poli.ufrj.br/monografias/monopoli10012506.pdf>>. Citado 4 vezes nas páginas 13, 14, 15 e 17.

LORENA, A. C.; CARVALHO, A. de. Uma introdução às support vector machines. *Revista de Informática Teórica e Aplicada*, v. 14, n. 2, p. 43–67, 2007. ISSN 21752745. Disponível em: <[https://seer.ufrgs.br/rita/article/view/rita\\_v14\\_n2\\_p43-67](https://seer.ufrgs.br/rita/article/view/rita_v14_n2_p43-67)>. Citado 2 vezes nas páginas 29 e 31.

LOUREIRO, S. M. *Reconhecimento Automático de Padrões de Falhas em Motobombas usando Análise de Sinais de Vibração*. Tese (Doutorado) — Universidade Federal do Espírito Santo, 2009. Citado 3 vezes nas páginas 9, 11 e 18.

MAFAULDA: Machinery fault database. 2017. Dados encontrados em <<http://www02.smt.ufrj.br/~offshore/mfs/index.html#TOC1>>, acessado em 01/10/2020. Citado 8 vezes nas páginas 5, 9, 14, 15, 16, 17, 21 e 33.

- MCKINNEY Wes. Data Structures for Statistical Computing in Python. In: WALT Stéfano van der; MILLMAN Jarrod (Ed.). *Proceedings of the 9th Python in Science Conference*. [S.l.: s.n.], 2010. p. 56 – 61. Citado na página 33.
- MOLNAR, C. *Interpretable machine learning*. [S.l.]: Lulu. com, 2020. <<https://christophm.github.io/interpretable-ml-book/>>, acessado em 01/04/2021. Citado na página 43.
- MONTE, M.; VERBELEN, F.; VERVISCH, B. The use of orbitals and full spectra to identify misalignment. In: . [S.l.]: Springer International Publishing, 2014. Citado na página 21.
- PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Citado 2 vezes nas páginas 31 e 33.
- PESTANA-VIANA, D. et al. The influence of feature vector on the classification of mechanical faults using neural networks. In: *2016 IEEE 7th Latin American Symposium on Circuits & Systems (LASCAS)*. Florianopolis: IEEE, 2016. p. 115–118. ISBN 978-1-4673-7835-2. Disponível em: <<https://ieeexplore.ieee.org/document/7451023/>>. Citado 3 vezes nas páginas 13, 26 e 37.
- PRÜFTECHNIK. *Condition Monitoring – Machinery Fault Diagnosis*. LUDECA, Inc, 2011. Disponível em: <[https://www.plantservices.com/assets/wp\\_downloads/pdf/111128-Ludeca-machinery-fault-diagnosis.pdf](https://www.plantservices.com/assets/wp_downloads/pdf/111128-Ludeca-machinery-fault-diagnosis.pdf)>. Citado 2 vezes nas páginas 19 e 20.
- RANDALL, R. State of the art in monitoring rotating machinery - part 1. *Sound and vibration*, v. 38, p. 14–21–13, 03 2004. Citado na página 8.
- RAUBER, T. W.; BOLDT, F. de A.; VAREJAO, F. M. Heterogeneous Feature Models and Feature Selection Applied to Bearing Fault Diagnosis. *IEEE Transactions on Industrial Electronics*, v. 62, n. 1, p. 637–646, jan. 2015. ISSN 0278-0046, 1557-9948. Disponível em: <<http://ieeexplore.ieee.org/document/6823731/>>. Citado 5 vezes nas páginas 5, 12, 26, 27 e 30.
- RAUBER, T. W. et al. Feature models and condition visualization for rotating machinery fault diagnosis. In: *2013 IEEE 20th International Conference on Electronics, Circuits, and Systems (ICECS)*. Abu Dhabi, United Arab Emirates: IEEE, 2013. p. 265–268. ISBN 978-1-4799-2452-3. Disponível em: <<http://ieeexplore.ieee.org/document/6815405/>>. Citado na página 12.
- RIBEIRO, F. M. L. *Similarity-based methods for machine diagnosis*. Tese (Tese de Doutorado) — Universidade Federal do Rio de Janeiro, 2018. Citado na página 24.
- ROCHA, D. S. C. *Aprendizado de máquina aplicado ao reconhecimento automático de falhas em máquinas rotativas*. Tese (Doutorado) — Universidade Federal de Minas Gerais, 2018. Citado 2 vezes nas páginas 13 e 37.
- SIMEONE, O. A brief introduction to machine learning for engineers. *CoRR*, abs/1709.02840, 2017. Disponível em: <<http://arxiv.org/abs/1709.02840>>. Citado na página 30.
- SKF Condition Monitoring. *Vibration diagnostic guide*. SKF Reliability Systems, 1994. Disponível em: <<http://edge.rit.edu/edge/P14453/public/Research/SKF%20VibrationGuide.pdf>>. Citado na página 21.



WANDEKOKEM, E. D. *Support Vector Machine Ensemble Based on Feature and Hyperparameter Variation*. Tese (Dissertação de Mestrado) — Universidade Federal do Espírito Santo, Vitória, 2011. Citado na página 9.

WANDEKOKEM, E. D. et al. Data-driven fault diagnosis of oil rig motor pumps applying automatic definition and selection of features. In: *2009 IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives*. Cargese, France: IEEE, 2009. p. 1–7. ISBN 978-1-4244-3440-4 978-1-4244-3441-1. Disponível em: <<http://ieeexplore.ieee.org/document/5292765/>>. Citado na página 12.

WANDEKOKEM, E. D. et al. Automatic Feature Definition and Selection in Fault Diagnosis of Oil Rig Motor Pumps. In: . Kuala Lumpur: [s.n.], 2009. v. 2, p. 737–742. Citado na página 12.

XIA, Z. et al. Spectral Regression Based Fault Feature Extraction for Bearing Accelerometer Sensor Signals. *Sensors*, v. 12, n. 10, p. 13694–13719, out. 2012. ISSN 1424-8220. Disponível em: <<http://www.mdpi.com/1424-8220/12/10/13694>>. Citado 3 vezes nas páginas 5, 26 e 27.

## APÊNDICE A – Gráficos em casacta


Na Figura 21 são mostrados gráficos em cascata para exemplos das quatro condições analisadas no trabalho. Foram selecionados os exemplos com maior severidade de cada defeito. Nos gráficos em cascata pode-se visualizar, ao mesmo tempo, o espectro em frequência de experimentos realizados em diferentes velocidades de rotação. Optou-se por representar o espectro em energia, que equivale ao quadrado da magnitude da FFT do sinal. Dessa forma, os picos destacam-se mais facilmente.

As linhas que atravessam o plano horizontal demarcam, em sequência, a posição dos picos em  $1\times$ ,  $2\times$  e  $3\times$  a velocidade de rotação. Validando algumas das discussões apresentadas na seção 3.2, nota-se que o espectro da condição de desbalanceamento (Figura 21b) costuma apresentar um pico destacado em  $1\times$  a rotação. Inclusive em comparação com os outros exemplos mostrados, a energia dos picos é muito superior à dos encontrados nas falhas de desbalanceamento e na condição normal.


Nos gráficos com defeito de desalinhamento (Figuras 21c e 21d), o pico em  $3\times$  a velocidade de rotação acaba se destacando e superando o pico em  $1\times$ . No entanto, isto só ocorre quando a rotação é mais elevada. Essa assinatura não está presente em rotações inferiores a 50 Hz, resultado este que aponta a um desafio à análise pela assinatura da falha. Em rotações mais baixas, provavelmente não há energia suficiente para a manifestação da assinatura esperada, o que impede diagnóstico do problema.

Figura 21 – Gráfico em cascata para cada condição, no eixo tangencial do primeiro mancal.


(a) Condição normal




(b) Desbalanceamento de 35 g



(c) Desalinhamento vertical de 1,9 mm



(d) Desalinhamento horizontal de 1,5 mm



Fonte: Próprio autor